

별무리

AI·SW 마에스트로 서울 제17기 / 2026.05 - 현재 / 온디바이스 AI 개발

스마트폰에서 캐릭터와 대화하고 알람과 일정 같은 기기 기능을 연결하는 iOS 앱입니다. 소형 언어 모델을 기기 안에서 실행하며, 저장한 대화 내용을 검색해 이후 답변에 사용합니다.

사용 기술: Unity / Swift / Gemma 4 E2B / LiteRT-LM / EmbeddingGemma / SQLite

소스 코드: <https://github.com/mornye-minor-gallery/PetAI-AI>

기술 문서: <https://pysunn.me/docs-beolmuri-ai/>

1. 일반 대화의 도구 호출 오인을 줄인 실행 의도 분류

• 문제

- 임베딩 유사도로 호출 후보를 판정했을 때, 일반 대화 24건 중 11건이 실행 요청으로 분류됐습니다.
- 작성중

• 해결 과정

- 작성중
- EmbeddingGemma의 768차원 벡터를 입력받는 경량 MLP를 도구 선택 앞에 추가했습니다.
 - 작성중
- MLP를 통과한 발화만 도구별 대표 벡터와 비교하고, 선택한 도구 하나의 정의를 모델에 전달해 JSON 인자를 생성했습니다.
 - 작성중
- 테스트
 - 기존 평가셋의 실제 실행 요청 168건과 일반 대화 24건으로 학습 구성을 비교했습니다.
 - 초기 MLP는 일반 대화 16건을 오인하고, 실제 실행 요청 163건을 탐지했습니다.
 - 비실행 사례만 보강한 구성은 일반 대화 2건을 오인하고, 실제 실행 요청 118건을 탐지했습니다.
 - 기능별 실행과 비실행 사례를 함께 보강한 구성은 일반 대화 2건을 오인하고, 실제 실행 요청 160건을 탐지했습니다.
 - 여기에 한국어 비실행 사례를 추가한 구성은 일반 대화 1건을 오인하고, 실제 실행 요청 159건을 탐지했습니다.

• 결과

- 일반 대화의 호출 후보 오인은 임베딩 기준선의 11/24건에서 마지막 MLP 구성의 1/24건으로 줄었습니다.
- 작성중

2. KV 캐시 재사용으로 첫 출력 대기 시간 단축

• 문제

- TestFlight 사용자에게 첫 답변이 늦게 나온다는 피드백을 받았습니다.
- 작성중

• 해결 과정

- CachedSession으로 메모리의 KV 캐시를 유지하고, 같은 고정 프롬프트를 다음 요청에 재사용했습니다.
 - 작성중
- 테스트
 - iPhone 17에서 같은 5턴 대화를 캐시 끄와 켜 조건으로 각각 3회 실행해 총 30개 요청을 비교했습니다.
 - 두 조건에서 생성한 답변 15쌍은 모두 일치했습니다.

• 결과

- 첫 출력 대기 시간은 전체 평균 4.920초에서 1.274초로 74.1% 줄었습니다.
- 후속 요청의 첫 출력 대기 시간은 평균 4.872초에서 0.446초로 90.8% 줄었습니다.

3. 앱 재실행 후 KV 캐시 재사용을 위한 추론 상태 저장과 복원

- 문제

- CachedSession으로 재사용하던 메모리의 KV 캐시는 앱을 종료하면 사라져, 재실행 시 같은 고정 프롬프트를 다시 계산해야 했습니다.
- 사용하던 LiteRT-LM의 공개 C API에는 추론 상태를 앱으로 내보내고 다시 복원하는 기능이 없었습니다.

- 해결 과정

- LiteRT-LM을 포크하고 CPU 세션의 추론 상태를 전송하는 C API를 추가했습니다.
 - 작성중
- 엔진에서 KV 텐서, 처리 위치, 토큰 ID와 샘플러 상태를 전송하고, Swift에서 파일 저장과 복원, 모델 정보와 체크섬 검사를 담당했습니다.
 - 작성중
- 테스트
 - 작성중

- 결과

- CPU 세션의 추론 상태를 앱에서 파일로 저장하고 복원하는 기능을 구현했습니다.
- 작성중